

TERI : Traitement et reconnaissance d'images

Cours Master 2 IAD

Isabelle Bloch - ENST / Département Signal & Images

Florence Tupin - ENST / Département Signal & Images

Antoine Manzanera – ENSTA / Unité d'Électronique et d'Informatique

Segmentation - Introduction

La segmentation d'images est l'un des problèmes phares du traitement d'images. Elle consiste à partitionner l'images en un ensemble de régions connexes. L'intérêt de ces régions est de pouvoir être manipulées ensuite via des traitements de haut niveau pour extraire des caractéristiques de forme, de position, de taille, etc.


Le problème est évidemment très mal posé, car on ne sait jamais dire quelle est la segmentation idéale. L'idée est bien sûr que la région se rapproche de la notion d'objet, au sens courant du terme. Néanmoins, on peut dégager des propriétés plus raisonnables qu'on cherche à obtenir dans un algorithme de segmentation, en particulier :

- *Stabilité* : la segmentation obtenue ne doit pas varier beaucoup lorsque les conditions d'acquisition varie légèrement (bruit, illumination, point de vue,...)
- *Régularité* : les régions obtenues doivent être simples à manipuler (taille suffisante, forme régulière,...)

Segmentation - Introduction



Segmentation



*Graphe d'adjacence
(Region Adjacency Graph)*

Segmentation – Plan du cours

I Méthodes statistiques

Histogrammes et Segmentation

Segmentation par sélection récursive sur histogrammes

II Méthodes géométriques

Region growing

Split & Merge

III Méthodes par optimisation



Définition d'une fonctionnelle de coût

Techniques d'optimisation


Segmentation par Histogrammes




Image couleur



Composante rouge

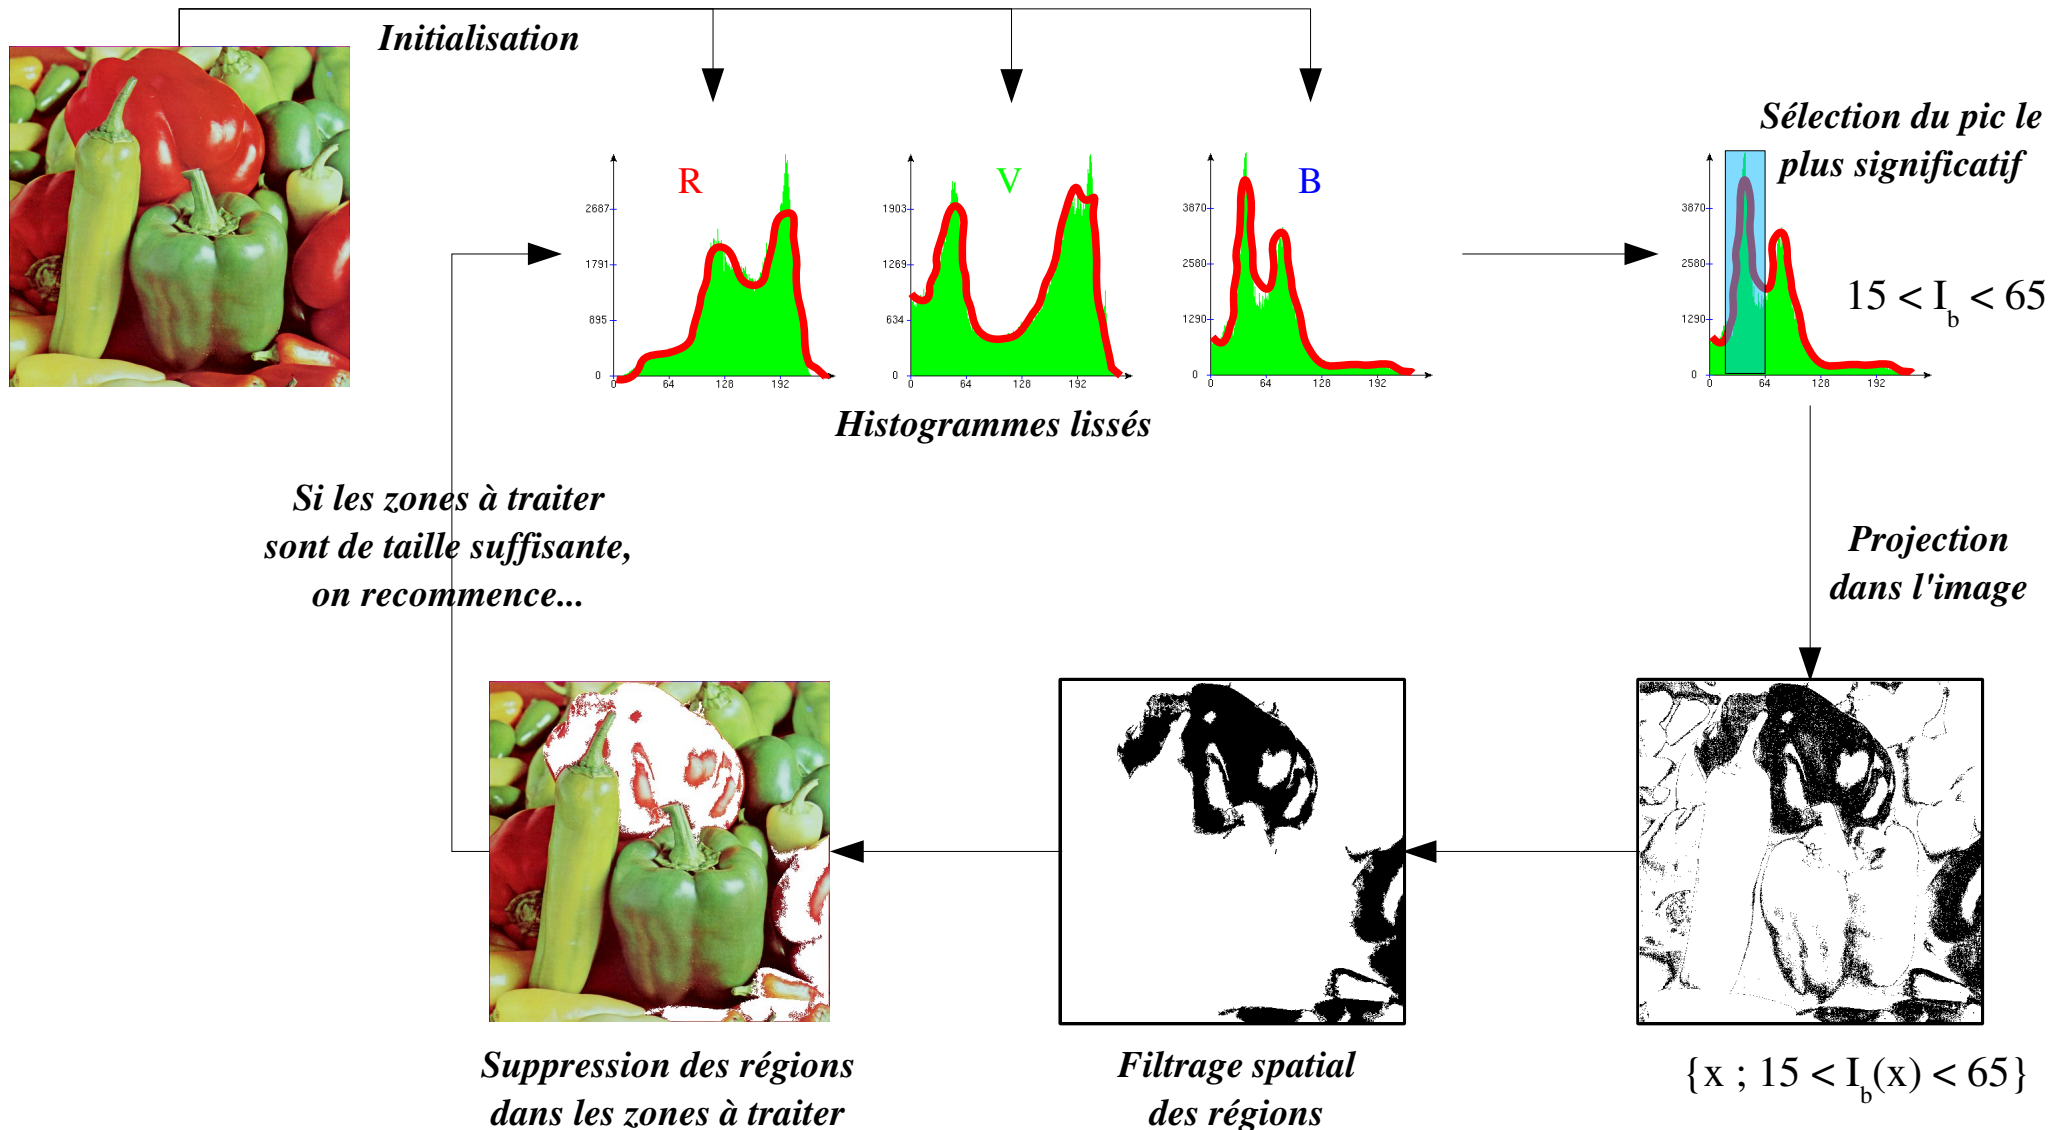


Composante verte



Composante bleue

Sélection Récursive sur Histogrammes



Segmentation : globale ou locale ?

Les méthodes par histogrammes sont en général :

- rapides à calculer
- peu sensibles au bruit

Mais elle n'intègrent pas (ou peu) d'information géométrique ou topologique sur les régions. Ce sont des méthodes *globales*, au sens où la décision d'appartenance d'un pixel à une région dépend toujours de l'image entière.

A l'autre extrême, on peut considérer les méthodes *locales*, pour lesquels l'étiquetage d'un pixel dépend uniquement, ou essentiellement, de son voisinage. L'exemple caractéristique est la segmentation par croissance de région (*region growing*). Ces algorithmes intègrent naturellement les propriétés topologiques, mais aussi parfois géométriques, des régions.

Region growing : principes

On initialise la région R à un pixel un groupe de pixels (*seed*).

La région R possède certains moyenne μ_R et écart-type σ_R .

On ajoute à R tous les pixels voisins de R qui sont suffisamment semblables à R , par ex:


$$|I(x) - \mu_R| < \text{seuil}$$

ou bien :

$$\begin{cases} \min \{ |I(x) - I(y)| ; y \in R \cap V(x) \} < \text{seuil} \\ |I(x) - \mu_R| < 2 \sigma_R. \end{cases}$$

On peut également ajouter des critères géométriques de régularité, comme par ex :


$R \cap V(x)$ est de cardinal au moins 3 et possède une seule composante connexe.



Region growing : exemple

- Remarques / Questions :


- Comment se comporte la méthode pour des gradients petits (régions type rampe) ?
- Régularité locale n'implique pas régularité de la région...



Region growing : exemple

- Remarques / Questions :

- Ce n'est en soi une méthode de segmentation : comment choisir convenablement les seeds de chaque région ?
- En général, l'ordre dans lequel les régions sont construites, mais aussi l'ordre dans lequel sont ajoutés les pixels dans une région a une grande influence sur le résultat.
- Implémentation : très rapide, si l'on utilise une structure de donnée adaptée (files d'attente).



Split & Merge : Principes




L'idée des algorithmes de type « Split & Merge » est de produire automatiquement une partition initiale en régions petites (Split), qui vont ensuite croître en se regroupant (Merge).

La partition initiale (Split) est réalisée en divisant récursivement l'image en régions de tailles identiques lorsqu'un certain critère d'homogénéité n'est pas satisfait (par ex: R est divisée si $\sigma_R > \text{seuil}$).





Lors de cette phase, le graphe d'adjacence, ou Region Adjacency Graph (RAG) est créé : à chaque région est associé un sommet du graphe, et des arêtes relient les sommets correspondants à deux régions qui se touchent.

La phase de regroupement (Merge) utilise le RAG pour modifier la partition initiale : pour chaque sommet R du RAG, on cherche s'il existe un sommet R' voisin dans le RAG et de valeur suffisamment proche, et si c'est le cas, on les fusionne (par ex: R et R' sont fusionnées si $|\mu_R - \mu_{R'}| < \text{seuil}$).




Split & Merge: Quad-tree split







Split & Merge: Quad-tree split







Split & Merge: Split & R.A.G.







Split & Merge: Split & R.A.G.



Split & Merge: R.A.G. & Merge



Split & Merge: R.A.G. & Merge



Split & Merge: Conclusions

Split : la géométrie du découpage a une grande influence sur le résultat de la segmentation. Par exemple, le split en quad-tree fait apparaître des régions carrées. D'autres types de découpage existent, éventuellement redondants (pyramides avec recouvrement).


Merge : l'ordre dans lequel est réalisé le regroupement des régions a aussi une influence sur le résultat. Comme illustré dans les planches précédentes, les algorithmes commencent en général à fusionner les régions les plus petites.

Méthodes par optimisation

Dans les méthodes par optimisation, le problème de la segmentation est formalisé par l'estimation d'une fonction f bidimensionnelle qui doit avoir certaines propriétés : régulière, constante par morceaux, aux bords réguliers, etc, tout en étant « proche » de l'image analysée I . On recherche un compromis entre ces différentes propriétés antagonistes, en minimisant une fonctionnelle de coût K qui va dépendre de :

- I l'image analysée.
- $\{R_i\}_{i \in P}$ la partition (segmentation) calculée.
- $\{\Gamma_j\}_{j \in Q}$ les courbes frontières (contours) associées à la segmentation.
- f la fonction recherchée, représentant l'image I segmentée. La fonction f est représentée par ses restrictions f_i sur chaque région R_i , soit :

$$f \equiv \{f_i\}_{i \in P}$$




Fonctionnelle de Mumford-Shah

Dans cette approche, le problème de la segmentation consiste à minimiser :

$$K(I, f, R, \Gamma) = \underbrace{\mu \sum_{i \in P} \iint_{R_i} (I(x, y) - f_i(x, y))^2 dx dy}_{\text{Terme de ressemblance}} + \underbrace{\sum_{i \in P} \iint_{R_i} \|\nabla f_i(x, y)\|^2 dx dy}_{\text{Terme de régularité}} + \underbrace{\nu \sum_{j \in Q} \int_{\Gamma_j} dl}_{\text{Terme de simplicité géométrique}}$$

- Terme de ressemblance à l'image originale.
- Terme de régularité des fonctions sur chaque région.
- Terme de simplicité géométrique (longueur des frontières).




Fonctionnelle de Mumford-Shah

Si l'on impose que chaque fonction f_i doit être constante sur la région R_i , le problème revient à minimiser la forme suivante (f_i est alors égale à la valeur moyenne de I sur la région R_i) :

$$K_0(I, f, R, \Gamma) = \frac{1}{\mu^2} K(I, f, R, \Gamma) = \sum_{i \in P} \iint_{R_i} (I(x, y) - f_i)^2 dx dy + \frac{\nu}{\mu^2} \sum_{j \in Q} \int_{\Gamma_j} dl$$

- La difficulté de mise en oeuvre de ces méthodes est liée au fait qu'on n'a pas – sauf cas particuliers – de solution directe au problème de minimisation. Les méthodes d'optimisation sont en général implémentées via 2 techniques différentes :

- Méthodes variationnelles sur des courbes fermées / régions isolées.
- Méthodes markoviennes par itération à partir d'une segmentation initiale.




Optimisation : Méthodes variationnelles


$$K_0(I, f, R, \Gamma) = \sum_{i \in P} \iint_{R_i} (I(x, y) - f_i)^2 dx dy + \alpha \sum_{j \in Q} \int_{\Gamma_j} dl$$

Une possible implantation de la segmentation par minimisation de fonction de coût consiste à partir d'une région (ou d'un contour fermée $\Gamma^{(1)}$) initial, et de le faire évoluer en déplaçant itérativement les points du contour tant que la fonction de coût associée diminue.

Ces méthodes s'apparentent aux techniques de contours actifs (snakes) :



$$C(s) = (x(s), y(s))$$



$$E = E_i + E_e$$

par exemple :

$$E_i = \int_0^1 \alpha (C'(s))^2 ds$$

(pénalise la longueur du snake)


$$E_e = \int_0^1 -\nabla I(x(s), y(s)) ds$$

(favorise l'alignement sur les forts gradients)

Optimisation : Méthodes markoviennes

$$K.(I, f, R, \Gamma) = \sum_{i \in P} \iint_{R_i} (I(x, y) - f_i)^2 dx dy + \alpha \sum_{j \in Q} \int_{\Gamma_j} dl$$

Une autre technique possible consiste à partir d'une segmentation préalable (de préférence une sur-segmentation, i.e. avec beaucoup de petites régions), puis d'ajuster localement les labels de chaque pixel de façon à diminuer (localement) la fonction de coût. Ces méthodes s'apparentent aux techniques markoviennes :



- séquentiel / parallèle ?
- déterministe / stochastique ?

Segmentation - Conclusion

